

基于 MACE-Field 与可解释机器学习的介电响应及介电击穿强度预测

目录

- 1. 项目背景
- 2. 项目主要目标
 - 2.1 利用 MACE-Field 预测介电常数
- 3. 利用机器学习势预测晶格振动
- 4. 基于唯象模型预测介电击穿强度
- 5. 可解释机器学习：重新发现介电击穿公式
- 6. 符号回归寻找新的物理公式
- 7. 进一步引入介电性质
- 8. 考虑薄膜厚度效应
- 9. 建立新的介电击穿物理模型
- 10. 项目具体技术路线
- 11. 项目实施步骤
- 12. 批量材料预测
- 13. 机器学习模型比较
- 14. 项目的核心科学问题
- 15. 预期成果

1. 项目背景

介电材料广泛应用于电容器、功率电子器件、绝缘器件以及微电子器件中。评价介电材料性能时，两个非常重要的物理量分别是：

- 介电常数 (dielectric constant)
- 介电击穿强度 (dielectric breakdown strength)

介电常数描述材料在外加电场作用下产生极化响应的能力。对于晶体材料，静态介电响应通常可以表示为：

$$\varepsilon_0 = \varepsilon_\infty + \varepsilon_{\text{ion}}$$

其中：

- ε_∞ ：电子介电常数，主要来源于电子云在外加电场下的响应；
- ε_{ion} ：离子介电贡献，主要来源于晶格振动和原子位移；
- ε_0 ：总的静态介电常数。

传统上，这些物理量通常需要采用密度泛函微扰理论（Density Functional Perturbation Theory, DFPT）进行计算。当研究对象扩展到数百甚至数千种材料时，第一性原理计算成本会迅速增加。

近年来，机器学习原子势（Machine-Learning Interatomic Potentials, MLIPs）快速发展，使得利用接近第一性原理精度的模型进行大规模材料性质预测成为可能。

其中，**MACE-Field** 在 MACE 机器学习势的基础上进一步考虑外加电场，可以从统一的电场相关能量模型中预测：

- 极化 (polarization)
- Born effective charge
- 极化率 (polarizability)
- Hessian / 力常数
- 电子介电响应
- 离子介电响应

因此，可以尝试建立从晶体结构出发快速预测介电性质的计算流程。

另一方面，介电击穿强度 E_b 表示介电材料在发生电学击穿之前能够承受的最大电场，是评价高压绝缘材料、高功率电子材料和储能介质的重要性能指标。

严格计算材料的本征介电击穿强度通常需要考虑电子在强电场下的能量获取以及电子-声子散射导致的能量耗散，计算成本较高。

已有研究利用机器学习分析一组晶体绝缘材料后发现，材料的：

- 带隙 E_g
- Γ 点最高声子频率 ω_{max}

与本征介电击穿强度存在较强关联，并建立了一个简单的唯象模型：


$$E_b = 24.442 \exp \left(0.315 \sqrt{E_g \omega_{\max}} \right)$$

其中：

- E_g 为材料带隙；
- $\omega_{\max}$ 为 Γ 点最大声子频率；
- E_b 为预测的介电击穿强度。

因此，本项目拟结合 MACE-Field、机器学习势和可解释机器学习方法，建立一个从晶体结构出发预测材料介电响应及介电击穿强度的计算流程，并进一步探索能否利用现代机器学习方法改进已有唯象模型，寻找更加准确且具有明确物理意义的新公式。

项目整体思路为：



2. 项目主要目标

本项目主要包括以下三个层次的任务。

2.1 利用 MACE-Field 预测介电常数

利用已有 MACE-Field 模型计算典型无机材料的介电性质，包括 ϵ_∞ 、 ϵ_{ion} ，以及

$$\epsilon_0 = \epsilon_\infty + \epsilon_{\text{ion}}$$

选择具有已有 DFPT 数据的材料作为测试集，对比：

$$\epsilon_{\infty}^{\text{MACE}} \quad \text{vs.} \quad \epsilon_{\infty}^{\text{DFT}}$$

以及

$$\epsilon_{\text{ion}}^{\text{MACE}} \quad \text{vs.} \quad \epsilon_{\text{ion}}^{\text{DFT}}$$

通过这一部分重点理解以下物理量之间的联系：

$$\text{极化} \rightarrow Z^* \rightarrow \text{力常数} \rightarrow \text{晶格响应} \rightarrow \epsilon_{\text{ion}}$$

其中， Z^* 表示 Born effective charge。

3. 利用机器学习势预测晶格振动

介电材料的晶格振动不仅决定离子介电响应，也与介电击穿过程中的电子-声子能量耗散密切相关。

利用 MACE 或 MACE-Field，可以计算体系能量关于原子位移的二阶导数，得到力常数矩阵：

$$\Phi_{ij} = \frac{\partial^2 E}{\partial R_i \partial R_j}$$

进一步构造动力学矩阵：

$$D_{ij} = \frac{\Phi_{ij}}{\sqrt{M_i M_j}}$$

其中 M_i 和 M_j 为相应原子的质量。

对动力学矩阵进行对角化，可以获得声子频率：

$$D\mathbf{e}_\nu = \omega_\nu^2 \mathbf{e}_\nu$$

重点提取 Γ 点最大声子频率：

$$\omega_{\max} = \max(\omega_\Gamma)$$

计算过程中可以结合以下工具：

- MACE / MACE-Field
- ASE
- Phonopy
- pymatgen

4. 基于唯象模型预测介电击穿强度

对于每一种材料，需要获得两个基本物理量： E_g 和 $\omega_{\max}$ 。

其中：

- E_g 可以来自第一性原理计算或者已有材料数据库；
- $\omega_{\max}$ 可以利用机器学习势计算得到。

然后代入已有介电击穿唯象公式：

$$E_b = 24.442 \exp \left[0.315 \sqrt{E_g \omega_{\max}} \right]$$

由此快速估算不同材料的介电击穿强度。

可以首先选择约 50–200 种结构相对简单、动力学稳定的无机绝缘材料，例如：

- 氧化物

- 氮化物
- 卤化物
- 硫族化合物
- 宽带隙半导体

建立如下材料数据库：

Material	E_g	$\omega_{\max}$	ϵ_{∞}	ϵ_{ion}	ϵ_0	E_b
Material 1						
Material 2						
Material 3						

进一步分析 $E_g \leftrightarrow E_b$ 、 $\omega_{\max} \leftrightarrow E_b$ ，以及 $\epsilon \leftrightarrow E_b$ 之间的相关关系。

5. 可解释机器学习：重新发现介电击穿公式

已有模型的核心形式为：

$$E_b = f(E_g, \omega_{\max})$$

一个重要研究问题是：利用目前更加先进的机器学习和可解释人工智能方法，能否重新发现或者改进这一唯象模型？

首先可以利用已有数据训练常规机器学习模型，例如：

- Linear Regression
- Polynomial Regression
- Random Forest
- XGBoost
- Gradient Boosting

输入特征可以包括 E_g 、 $\omega_{\max}$ ，以及二者的组合特征：

$$E_g \omega_{\max}, \quad \sqrt{E_g \omega_{\max}}, \quad \ln E_g, \quad \ln \omega_{\max}$$

然后比较不同模型对 E_b 的预测能力。评价指标可以采用 R^2 、 MAE 以及 $RMSE$ 。

6. 符号回归寻找新的物理公式

相比 Random Forest 或 XGBoost，符号回归的优势是最终能够给出一个明确的数学表达式。

推荐尝试：

- PySR
- gplearn
- 其他 symbolic regression 类方法

基本目标可以写成：

$$E_b = f(E_g, \omega_{\max})$$

让算法自动搜索类似以下形式的表达式：

$$E_b = A E_g^\alpha \omega_{\max}^\beta$$

或者

$$E_b = A \exp \left(B \sqrt{E_g \omega_{\max}} \right)$$

以及其他自动生成的数学表达式。

模型选择不应仅以预测误差作为唯一标准，还需要同时考虑：

1. 预测准确性
2. 数学表达式复杂程度
3. 参数数量
4. 公式稳定性
5. 物理可解释性

因此，可以建立一个基本原则：

好的模型 = 较高预测精度 + 较低复杂度 + 明确物理意义

7. 进一步引入介电性质

已有介电击穿唯象模型只考虑 E_g 和 $\omega_{\max}$ 。但实际上，介电响应本身可能也与介电击穿有关。

因此可以进一步研究：

$$E_b = f(E_g, \omega_{\max}, \varepsilon_{\infty}, \varepsilon_{\text{ion}})$$

甚至进一步考虑：

$$E_b = f(E_g, \omega_{\max}, \varepsilon_0)$$

可以利用：

- Pearson correlation
- Spearman correlation
- Random Forest feature importance
- Permutation importance
- SHAP

分析不同物理量对于击穿强度预测的重要程度。例如研究 E_g 、 $\omega_{\max}$ 、 ϵ_{∞} 、 ϵ_{ion} 中，哪些变量对 E_b 的影响最明显。

8. 考虑薄膜厚度效应

前面的模型主要针对材料的本征介电击穿强度。但实际实验中测量到的击穿强度通常还受到材料尺寸和微结构的影响，例如：

- 薄膜厚度
- 缺陷
- 晶粒尺寸
- 界面
- 温度
- 制备条件

其中，薄膜厚度 d 是一个比较容易获得，同时又具有明确实际意义的参数。因此，可以进一步考虑：

$$E_b = f(E_g, \omega_{\max}, d)$$

例如可以首先测试下面这种候选形式：

$$E_b = A \exp \left(B \sqrt{E_g \omega_{\max}} \right) \left(\frac{d}{d_0} \right)^{-n}$$

其中：

- A 为比例系数；
- B 描述带隙和声子频率对击穿的影响；
- n 描述厚度依赖关系；
- d_0 为参考厚度。

对上式取对数：

$$\ln E_b = \ln A + B\sqrt{E_g\omega_{\max}} - n \ln \left(\frac{d}{d_0} \right)$$

这样可以将 E_g 、 $\omega_{\max}$ 以及 d 同时纳入模型。这个模型可以理解为：

电子激发 + 晶格振动 + 材料尺度 $\rightarrow$ 介电击穿

需要注意的是：**厚度不是材料本征击穿强度的内禀变量。**

因此，如果引入厚度 d ，训练目标应该采用不同厚度薄膜的实验击穿强度，而不能简单将厚度加入原有本征击穿数据库。这一点也是区分

intrinsic property（本征性质）与 **measured device property**（器件实测性质）

的重要内容。

9. 建立新的介电击穿物理模型

如果数据量足够，可以进一步构造更加一般的模型：

$$E_b = f(E_g, \omega_{\max}, \varepsilon_{\infty}, \varepsilon_{\text{ion}}, d)$$

例如可以尝试寻找：

$$E_b = A E_g^{\alpha} \omega_{\max}^{\beta} \varepsilon^{-\gamma} d^{-n}$$

对数化后：

$$\ln E_b = \ln A + \alpha \ln E_g + \beta \ln \omega_{\max} - \gamma \ln \varepsilon - n \ln d$$

其中 α 、 β 、 γ 、 n 均由数据自动确定。

重点不是预先假设该公式一定成立，而是利用机器学习判断：

- 是否需要 ε
- 是否存在明显厚度效应
- 各物理量对应的指数是多少
- 新公式是否能够同时提高精度和物理可解释性


最终希望建立类似


$$E_b = f(E_g, \omega_{\max}, \varepsilon, d)$$

的新型介电击穿描述模型。


10. 项目具体技术路线

整体技术路线可以表示为：





进一步进入机器学习阶段：



最后进行符号回归：

$E_g + \omega_{\max} + \epsilon^{\infty} + \epsilon_{\text{ion}} (+ d)$



Symbolic Regression



自动搜索数学表达式



精度 + 简洁性 + 物理意义



新的介电击穿公式

11. 项目实施步骤

第一阶段：基础知识与计算环境

主要学习：

- Python
- NumPy
- pandas
- matplotlib
- ASE
- pymatgen

同时理解：

- 晶体结构
- 能带
- 带隙
- 极化
- 介电常数
- Born effective charge
- 声子
- 介电击穿

这一阶段重点是理解基本物理概念，不需要深入推导复杂的 DFPT 理论。

第二阶段：MACE-Field 基础计算

安装并学习使用：

- MACE
- MACE-Field
- ASE
- Phonopy

首先从少量简单材料开始测试，例如：

- MgO
- Al₂O₃
- SiO₂
- AlN
- GaN

计算 ϵ_{∞} 、 ϵ_{ion} 以及 ω_{max} 。

第三阶段：模型精度验证

选择已有第一性原理数据作为参考，对比 MACE-Field 的预测结果。

绘制电子介电常数 parity plot：

$$\epsilon_{\infty}^{\text{MACE}} \quad \text{vs.} \quad \epsilon_{\infty}^{\text{DFT}}$$

离子介电常数 parity plot：

$$\epsilon_{\text{ion}}^{\text{MACE}} \quad \text{vs.} \quad \epsilon_{\text{ion}}^{\text{DFT}}$$

声子频率 parity plot：

$$\omega_{\max}^{\text{MACE}} \quad \text{vs.} \quad \omega_{\max}^{\text{DFT}}$$

计算 R^2 、MAE 以及 RMSE。

12. 批量材料预测

在模型验证完成后，将计算扩展到几十至几百种材料。建立完整数据集，字段包括：

```
material_id  
formula  
crystal_structure  
Eg  
omega_max  
epsilon_electronic  
epsilon_ionic  
epsilon_static  
Eb
```

进一步绘制：

- E_g 分布
- $\omega_{\max}$ 分布
- ϵ_0 分布
- E_b 分布
- E_g 与 E_b 关系
- $\omega_{\max}$ 与 E_b 关系
- ϵ 与 E_b 关系

同时比较不同材料类别之间的差异。

13. 机器学习模型比较

建立训练集和测试集，例如：

80% training, 20% testing

训练不同模型：

1. Linear Regression
2. Polynomial Regression
3. Random Forest
4. XGBoost
5. Symbolic Regression

评价不同模型的 R^2 、MAE、RMSE。

需要特别关注一个问题：**更复杂的机器学习模型是否真的显著优于简单物理公式？**

如果复杂模型只提高很小的精度，而简单模型可以得到明确的数学公式，那么简单模型可能具有更高的科学价值。

14. 项目的核心科学问题

本项目重点希望回答以下几个问题。

问题 1

机器学习原子势能否准确预测材料的 ϵ_∞ 、 ϵ_{ion} 以及 ω_{max} ？

问题 2

为什么 E_g 和 ω_{max} 能够较好地描述介电击穿强度？

可以从以下角度进行理解：

- 电子激发
- 电子加速
- 电子-声子散射
- 晶格能量耗散

问题 3

利用现代机器学习方法，能否重新发现已有关系：

$$E_b \propto \exp \left(\sqrt{E_g \omega_{\max}} \right)$$

如果能够重新发现类似形式，可以进一步验证这一关系是否具有普适性。

问题 4

加入 ϵ_{∞} 或者 ϵ_{ion} 之后，能否显著改善介电击穿强度预测？

问题 5

对于实验薄膜材料，是否可以利用 E_g 、 $\omega_{\max}$ 、 ϵ 、 d 建立统一的介电击穿模型：

$$E_b = f(E_g, \omega_{\max}, \epsilon, d)$$

15. 预期成果

项目完成后，预期形成以下成果：

1. 建立 MACE-Field 介电性质计算流程；
2. 获得一批无机材料的 ϵ_{∞} 、 ϵ_{ion} 、 ϵ_0 、 $\omega_{\max}$ ；
3. 系统评价 MACE-Field 对介电性质和声子性质的预测精度；
4. 复现已有介电击穿唯象模型；
5. 建立材料介电击穿性质数据库；
6. 利用传统机器学习分析不同物理量与 E_b 的关系；
7. 利用符号回归寻找新的解析公式；
8. 探索介电常数和薄膜厚度对于击穿模型的影响；
9. 最终形成完整的

结构 → 介电性质 → 声子 → 介电击穿

机器学习预测流程。